Avaliando a Capacidade de Modelos de Aprendizado de Máquina Treinados com Dados Sintéticos de Críticas em Filmes e Séries

Davi Romauski Meurer[1], **Marlon Marcon**[1]

[1]Departamento de Engenharia de Software
Universidade Tecnológica Federal do Paraná (UTFPR) – Dois Vizinhos, PR – Brasil

davimeurer@alunos.utfpr.edu.br, marlonmarcon@utfpr.edu.br

Abstract.

Resumo.

1. Introdução

A análise de sentimento é uma tarefa de classificação de texto que busca identificar a polaridade — positiva, negativa ou neutra — de uma opinião expressa em linguagem natural. Essa tarefa tem aplicações diretas em áreas como mineração de opinião, monitoramento de redes sociais e análise de feedback de produtos e serviços [Jurafsky and Martin 2025]. No domínio de entretenimento, a classificação automática de críticas de filmes e séries permite compreender, em larga escala, como o público reage a uma obra, algo que seria inviável de forma manual dada a quantidade de conteúdo gerado diariamente em plataformas de avaliação.

No entanto, treinar modelos de aprendizado de máquina para essa tarefa depende de datasets rotulados de qualidade, cuja construção manual é custosa, demorada e suscetível a inconsistências entre anotadores humanos. Esse problema é ainda mais acentuado em língua portuguesa, onde a disponibilidade de recursos linguísticos anotados é significativamente menor quando comparada ao inglês [Souza and Filho 2021]. A escassez de dados rotulados em português brasileiro representa um dos principais obstáculos para o avanço de pesquisas em Processamento de Linguagem Natural (PLN) voltadas a esse idioma.

Uma alternativa que vem ganhando atenção na literatura recente é o uso de Grandes Modelos de Linguagem (*Large Language Models* — LLMs) como geradores de dados sintéticos de treinamento [Liu et al. 2024, Nadas et al. 2025]. Modelos como ChatGPT, Gemini e Claude demonstram capacidade de produzir textos coerentes e contextualmente adequados em diversas línguas, o que abre a possibilidade de utilizá-los para criar datasets rotulados sem depender de anotação humana. Trabalhos recentes já investigaram essa abordagem para tarefas como classificação de texto e análise de sentimento baseada em aspectos, com resultados promissores em cenários de poucos recursos [Li et al. 2023, Hellwig et al. 2025].

Este trabalho investiga se dados sintéticos gerados por três LLMs distintos — ChatGPT, Gemini e Claude — são suficientes para treinar modelos clássicos de aprendizado de máquina capazes de classificar o sentimento de críticas de filmes e séries em português brasileiro. O dataset utilizado contém 1798 frases distribuídas em três

classes (Positiva, Negativa e Neutra), geradas integralmente por esses modelos. Além de avaliar a assertividade dos classificadores treinados com esses dados, o trabalho analisa se há coerência na classificação entre os dados produzidos por cada LLM gerador. Para isso, são empregados três algoritmos — Naive Bayes, Regressão Logística e SVM Linear — avaliados por meio de métricas como acurácia, F1-Score, validação cruzada estratificada e análise de erros por fonte geradora.

Este artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica sobre análise de sentimento, representação de texto e os algoritmos utilizados. A Seção 3 revisa trabalhos relacionados na literatura. A Seção 4 descreve a metodologia adotada para geração dos dados e treinamento dos modelos. A Seção 5 apresenta e discute os resultados obtidos. Por fim, a Seção 6 traz as conclusões e direções para trabalhos futuros.

2. Fundamentação Teórica

Esta seção apresenta os conceitos que embasam o trabalho: análise de sentimento como tarefa de PLN, as técnicas de representação de texto utilizadas, os algoritmos de classificação adotados e o papel dos grandes modelos de linguagem na geração de dados sintéticos.

2.1. Análise de Sentimento

A análise de sentimento é uma das tarefas mais estudadas em Processamento de Linguagem Natural (PLN). O objetivo principal é identificar automaticamente a polaridade de um texto — se ele expressa uma opinião positiva, negativa ou neutra em relação a algum objeto, produto ou experiência [Jurafsky and Martin 2025]. As aplicações são diversas: desde monitoramento de redes sociais e análise de reputação de marcas até pesquisas de satisfação e moderação de conteúdo.

Do ponto de vista da granularidade, a análise de sentimento pode ser realizada em três níveis: no nível do documento, avaliando o sentimento geral do texto como um todo; no nível da sentença, classificando cada frase individualmente; e no nível de aspecto, identificando a polaridade em relação a atributos específicos de um produto ou serviço [Pang et al. 2002]. Neste trabalho, a classificação é feita no nível da sentença, com três classes possíveis: Positiva, Negativa e Neutra.

Um dos desafios conhecidos da tarefa é o tratamento de negações e ambiguidades linguísticas. Uma frase como “não gostei nada desse filme” tem polaridade oposta ao que seria esperado pela presença isolada do verbo “gostar”, e esse tipo de construção tende a causar erros em classificadores baseados apenas em frequência de termos [Jurafsky and Martin 2025].

2.2. Representação de Texto: *Bag-of-Words* e TF-IDF

Para que algoritmos de aprendizado de máquina possam processar texto, é necessário converter as frases em representações numéricas. A abordagem *bag-of-words* (BoW) é uma das mais simples e tradicionais: cada documento é representado como um vetor de contagens de palavras, ignorando a ordem em que aparecem [Jurafsky and Martin 2025]. Apesar de sua simplicidade, essa representação ainda apresenta resultados competitivos em muitas tarefas de classificação de texto.

Uma extensão comum do BoW é o *Term Frequency–Inverse Document Frequency* (TF-IDF), que ajusta as contagens de palavras pela frequência inversa delas no corpus. A ideia é penalizar termos muito frequentes — como preposições e artigos — que aparecem em quase todos os documentos e, portanto, têm pouco poder discriminativo. Formalmente, o peso TF-IDF de um termo t em um documento d é dado por:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log\left(\frac{N}{\text{DF}(t)}\right) \tag{1}$$

onde N é o número total de documentos e $\text{DF}(t)$ é o número de documentos que contêm o termo t. O TF-IDF foi escolhido neste trabalho como método de vetorização por ser amplamente utilizado em tarefas de classificação de sentimento e por apresentar bom desempenho com classificadores clássicos [Rossi 2019].

2.3. Algoritmos de Classificação

2.3.1. Naive Bayes

O classificador Naive Bayes é um método probabilístico baseado no Teorema de Bayes, que assume independência condicional entre os atributos dado a classe. Embora essa suposição raramente seja verdadeira na prática — daí o nome "naive" (ingênuo) —, o algoritmo apresenta resultados surpreendentemente bons em tarefas de classificação de texto [Jurafsky and Martin 2025]. Na versão multinomial, utilizada neste trabalho, o modelo calcula a probabilidade de cada classe dado o conjunto de termos presentes na frase e escolhe a classe de maior probabilidade a posteriori.

2.3.2. Regressão Logística

A Regressão Logística é um classificador discriminativo que aprende diretamente a fronteira de decisão entre as classes, ao contrário do Naive Bayes, que modela a distribuição gerativa dos dados [Jurafsky and Martin 2025]. Em geral, classificadores discriminativos tendem a superar o Naive Bayes quando há grande quantidade de dados, pois não impõem a suposição de independência entre as *features* [Pang et al. 2002]. Contudo, como discutido na seção de Resultados, os dados obtidos neste trabalho apresentaram o comportamento inverso, o que pode estar relacionado às características específicas dos dados sintéticos gerados por LLMs.

2.3.3. Support Vector Machine

A Support Vector Machine (SVM) é um algoritmo que busca o hiperplano de separação de máxima margem entre as classes no espaço de *features*. Com kernel linear, é especialmente eficaz para problemas de alta dimensionalidade como classificação de texto, onde o número de *features* (vocabulário) pode ser muito maior do que o número de exemplos [Jurafsky and Martin 2025]. Neste trabalho, o SVM com kernel linear foi utilizado como terceiro modelo de comparação.

2.4. Grandes Modelos de Linguagem e Geração de Dados Sintéticos

Grandes Modelos de Linguagem (*Large Language Models* — LLMs) são modelos baseados na arquitetura Transformer, pré-treinados em grandes corpora de texto para aprender representações ricas da linguagem. Nos últimos anos, modelos como GPT, Gemini e Claude demonstraram capacidade de gerar textos coerentes, fluentes e contextualmente adequados em diversas línguas e domínios [Jurafsky and Martin 2025].

Uma das aplicações emergentes dos LLMs é a geração de dados sintéticos para treinamento de modelos de aprendizado de máquina. Essa abordagem é especialmente interessante em cenários onde a obtenção de dados reais rotulados é cara ou difícil — como é frequentemente o caso em tarefas de PLN em português. A ideia central é usar os LLMs como geradores de exemplos de treinamento, reduzindo a dependência de anotação humana.

2.5. Métricas de Avaliação

A avaliação de classificadores requer métricas que capturem diferentes aspectos do desempenho do modelo. Neste trabalho, são utilizadas quatro métricas principais, seguindo as recomendações de [Sokolova and Lapalme 2009]: acurácia, que mede a proporção de classificações corretas sobre o total; precisão, que indica a proporção de verdadeiros positivos entre todas as predições positivas de uma classe; recall, que mede a proporção de verdadeiros positivos entre todos os exemplos reais de uma classe; e F1-Score, que é a média harmônica entre precisão e recall, sendo especialmente útil quando se deseja um equilíbrio entre ambas.

Para obter estimativas mais robustas do desempenho dos modelos, foi adotada a validação cruzada estratificada com $k = 10$ folds, conforme recomendado por [Kohavi 1995] como o método mais adequado para seleção e avaliação de modelos em datasets de tamanho moderado. Essa técnica divide o dataset em 10 partições mantendo a proporção das classes em cada fold, de modo que cada partição é usada uma vez como conjunto de teste enquanto as demais servem para treinamento. Todo o pipeline de vetorização, treinamento e avaliação foi implementado com a biblioteca scikit-learn [Pedregosa et al. 2011].

3. Trabalhos Relacionados

Esta seção revisa trabalhos que abordam análise de sentimento com aprendizado de máquina, com foco em aplicações em língua portuguesa e no uso de dados sintéticos para treinamento de classificadores.

3.1. Análise de Sentimento com Aprendizado de Máquina

O trabalho pioneiro de [Pang et al. 2002] estabeleceu que abordagens baseadas em aprendizado de máquina — especialmente Naive Bayes, SVM e Máxima Entropia — superam métodos baseados em regras para classificação de sentimento em resenhas de filmes. Os autores utilizaram o corpus de críticas do IMDb e observaram que o SVM com representação unigrama atingiu os melhores resultados (82,9% de acurácia), enquanto o Naive Bayes apresentou desempenho competitivo com menor custo computacional. Esse resultado é relevante para o presente trabalho porque demonstra, já em 2002, que

classificadores clássicos com representações simples são capazes de capturar a polaridade de críticas de cinema com boa acurácia.

No contexto brasileiro, [Kansaon and Moro 2019] realizaram análise de sentimento em tweets em português, utilizando múltiplas variantes do Naive Bayes. Os autores reportaram acurácias entre 79% e 85% dependendo da configuração do classificador e do par de classes analisado, evidenciando que mesmo em língua portuguesa, com suas particularidades morfológicas, abordagens clássicas apresentam resultados satisfatórios. [de Souza et al. 2021] propuseram um sistema de análise de sentimento em tempo real para notícias do mercado financeiro em português, utilizando TF-IDF combinado com Naive Bayes, e atingiram acurácia de 76,8% na classificação de tweets jornalísticos. [Rossi 2019] comparou classificadores como Regressão Logística, Naive Bayes Multinomial, SVM linear e Random Forest sobre representações BoW e TF-IDF em um contexto de cidades inteligentes, demonstrando que o TF-IDF apresenta ganhos consistentes sobre o BoW simples na maioria dos cenários. [Souza and Filho 2021] unificaram cinco datasets de análise de sentimento em português brasileiro e evidenciaram a escassez de recursos linguísticos anotados para o idioma, o que reforça a necessidade de alternativas como a geração de dados sintéticos.

3.2. Dados Sintéticos e LLMs para Geração de Dados de Treinamento

A utilização de dados sintéticos gerados por LLMs para treinamento de modelos de aprendizado de máquina é uma área recente de pesquisa. [Zhang et al. 2024] realizaram uma avaliação abrangente do desempenho de LLMs em tarefas de análise de sentimento, comparando-os com modelos menores *fine-tuned*. Os resultados indicam que LLMs apresentam desempenho satisfatório em tarefas mais simples de classificação de polaridade, mas ficam atrás em tarefas que requerem compreensão mais profunda de fenômenos de sentimento, como detecção de ironia ou análise baseada em aspectos. Esse resultado sugere que os LLMs podem ser mais confiáveis como geradores de dados para tarefas de polaridade simples do que para tarefas mais complexas.

[Hellwig et al. 2025] exploraram o uso de GPT-3.5-turbo e Llama-3-70B para gerar dados anotados para análise de sentimento baseada em aspectos (ABSA) em cenários de poucos recursos. Com apenas 25 exemplos de referência, a adição de dados sintéticos via *few-shot prompting* resultou em ganhos expressivos de F1-Score, demonstrando que mesmo pequenas quantidades de dados sintéticos podem complementar datasets escassos. [Li et al. 2023] avaliaram a geração de dados sintéticos com GPT-3.5-Turbo para classificação de texto e reportaram que a efetividade dos dados gerados varia conforme a subjetividade da tarefa — tarefas mais objetivas tendem a se beneficiar mais, o que é relevante para o presente trabalho já que a classificação de sentimento de filmes envolve um grau moderado de subjetividade.

Do ponto de vista metodológico, [Liu et al. 2024] compilaram as melhores práticas para uso de dados sintéticos no treinamento de modelos de linguagem, incluindo técnicas de filtragem, ponderação e refinamento iterativo, além de discutir riscos como amplificação de viés e colapso de modelo. [Nadas et al. 2025] apresentaram o survey mais recente sobre o tema, cobrindo desde geração baseada em prompts até pipelines com refinamento iterativo, e destacaram que a abordagem é especialmente promissora para tarefas com poucos recursos em idiomas que não o inglês. [Araujo et al. 2024]

investigaram especificamente as capacidades do ChatGPT para análise de sentimento zero-shot em português brasileiro, demonstrando que o modelo se destaca na determinação de polaridade, embora tenha dificuldades com sentenças subjetivas e comparativas — resultado que valida o uso de LLMs como geradores de dados de sentimento em português.

3.3. Posicionamento deste Trabalho

A maioria dos trabalhos revisados utiliza LLMs como classificadores diretos em cenários zero-shot ou few-shot, e não como geradores de dados de treinamento para modelos clássicos. Além disso, a maior parte das pesquisas foca no idioma inglês e utiliza um único LLM como fonte de dados. Este trabalho se diferencia em três aspectos: utiliza dados 100% sintéticos gerados por três LLMs distintos (ChatGPT, Gemini e Claude) como conjunto de treinamento, foca em português brasileiro, e analisa não apenas a acurácia dos classificadores, mas também a coerência dos dados gerados entre os diferentes modelos — uma perspectiva pouco explorada na literatura até o momento.

4. Metodologia

Esta seção descreve o pipeline completo adotado no trabalho, desde a definição das classes e geração do dataset sintético até o protocolo de avaliação dos classificadores. As subseções a seguir detalham cada etapa com as respectivas justificativas das escolhas realizadas.

4.1. Definição das Classes de Sentimento

Para garantir consistência na geração e coerência na classificação dos dados, foram estabelecidas definições explícitas para cada classe de sentimento, focadas no domínio de críticas de filmes e séries de televisão em português brasileiro [Jurafsky and Martin 2025]. A definição prévia das classes foi necessária para que os prompts enviados aos LLMs fossem suficientemente precisos e para reduzir a ambiguidade nas frases geradas.

A classe **Positiva** contempla críticas ou comentários que expressam sentimentos de satisfação, admiração ou recomendação explícita sobre uma obra, incluindo elogios a elementos específicos como atuação, roteiro, direção ou impacto emocional. A classe **Negativa** abrange textos que expressam insatisfação, desapontamento ou desaprovação, com críticas a aspectos como roteiro inconsistente, ritmo lento ou personagens mal desenvolvidos. Por fim, a classe **Neutra** compreende textos com informações factuais sobre a obra — sinopses, descrição de elenco, dados de lançamento — sem emitir juízo de valor. Os exemplos a seguir ilustram cada classe:

> *Positiva: "Adorei o filme, o roteiro é top e as atuações são ótimas. Recomendo a todos!"*
> *Negativa: "Que decepção, o filme tem um roteiro cheio de furos e os personagens são muito chatos."*
> *Neutra: "A série foi dirigida por Anna Kappel e estreou em 2025 na plataforma de streaming."*

4.2. Construção do Dataset

O dataset foi construído inteiramente a partir de dados sintéticos gerados por três LLMs: ChatGPT (OpenAI), Gemini (Google) e Claude (Anthropic). A escolha por múltiplos

modelos geradores teve como objetivo reduzir o viés de geração associado a uma única fonte, já que cada LLM possui características próprias de vocabulário, estrutura de frases e estilo de escrita. A proposta original do trabalho previa o uso do Copilot (Microsoft) como terceira fonte, mas o modelo foi substituído pelo Claude porque o Copilot utiliza modelos da família GPT por baixo, o que resultaria em dois geradores com a mesma base e comprometeria a diversidade estilística do dataset.

Para cada LLM, foram solicitadas 200 frases por classe de sentimento via prompts padronizados, enviados manualmente pelas interfaces web dos respectivos modelos. Os prompts descreviam a classe desejada, forneciam a definição adotada e restringiam o domínio a críticas de cinema e séries em português brasileiro. O processo resultou em 9 arquivos CSV (3 modelos × 3 classes), posteriormente unificados em um único dataset. A Tabela 1 apresenta a composição final após a etapa de limpeza.

Table 1. Distribuição de frases por fonte geradora e classe de sentimento.

Fonte	Positiva	Negativa	Neutra	Total
ChatGPT	200	198	200	598
Claude	200	200	200	600
Gemini	200	200	200	600
Total	**600**	**598**	**600**	**1798**

As três fontes apresentam características estilísticas distintas, com diferenças notáveis no comprimento médio das frases: o ChatGPT produz textos mais curtos e diretos (média de aproximadamente 50 caracteres), o Gemini gera frases intermediárias (61 caracteres) com vocabulário mais descritivo, e o Claude produz frases consideravelmente mais longas e elaboradas (95 caracteres). Essa diversidade estilística entre as fontes é relevante para a análise de erros discutida na Seção 5.

4.3. Pré-processamento

Antes da vetorização, os textos brutos passaram por quatro operações sequenciais de limpeza: conversão de todos os caracteres para minúsculas, remoção de pontuação, números e caracteres especiais, normalização de espaços extras e eliminação de frases duplicadas. A normalização para minúsculas foi adotada de modo a garantir que variações de capitalização não gerem features distintas no vocabulário — “Filme” e “filme” são tratados como o mesmo token. A remoção de duplicatas eliminou 2 frases do conjunto original de 1800, resultando no dataset final de 1798 amostras únicas.

4.4. Vetorização

A conversão dos textos em representações numéricas foi realizada com o `TfidfVectorizer` do scikit-learn [Pedregosa et al. 2011], com os parâmetros padrão da biblioteca, sem limitação de vocabulário e sem remoção explícita de stopwords. A fundamentação teórica do TF-IDF está descrita na Seção 2.2. A escolha dessa técnica de vetorização justifica-se pelo seu desempenho comprovado em tarefas de classificação de sentimento combinadas com classificadores baseline [Pang et al. 2002, Souza and Filho 2021] e por sua eficiência computacional para vocabulários de tamanho

moderado. Cada frase foi transformada em um vetor esparso de dimensão igual ao tamanho do vocabulário completo do corpus de treino.

4.5. Modelos de Classificação

Três classificadores foram treinados e avaliados, todos implementados via scikit-learn [Pedregosa et al. 2011] com hiperparâmetros padrão da biblioteca. O uso dos parâmetros padrão foi intencional: o objetivo do trabalho não é otimizar configurações, mas avaliar a capacidade de generalização dos classificadores clássicos quando treinados exclusivamente com dados sintéticos. O Naive Bayes Multinomial foi instanciado com `MultinomialNB()` (alpha=1,0), a Regressão Logística com `LogisticRegression(random_state=42)` (C=1,0, solver=lbfgs, estratégia one-vs-rest) e o SVM Linear com `LinearSVC(random_state=42, max_iter=5000)` (C=1,0, estratégia one-vs-rest). A descrição teórica de cada algoritmo está apresentada na Seção 2.3.

4.6. Protocolo de Avaliação

A avaliação foi conduzida em três etapas progressivas. Na primeira, o dataset foi dividido em 80% para treino (1438 amostras) e 20% para teste (360 amostras), com estratificação por classe (`stratify=y`) e semente fixa (`random_state=42`) para garantir reprodutibilidade. Nessa configuração foram calculadas acurácia, precisão, recall e F1-Score ponderado para os três modelos.

Na segunda etapa, foi aplicada a validação cruzada estratificada com k=5 e k=10 folds [Kohavi 1995], que fornece estimativas mais robustas do desempenho ao garantir que cada amostra seja utilizada exatamente uma vez como conjunto de teste. Os resultados são reportados como média e desvio padrão do F1-Score e da acurácia ao longo dos folds. Na terceira etapa, foram geradas curvas de aprendizado para os três modelos, variando a fração de dados de treino de 10% a 100% com validação cruzada de 5 folds em cada ponto, de modo a diagnosticar a presença de overfitting e avaliar a sensibilidade dos modelos ao volume de dados. Por fim, uma análise qualitativa dos erros do Naive Bayes foi conduzida, identificando padrões de confusão entre classes e diferenças de desempenho por fonte geradora.

4.7. Ambiente Experimental

Todos os experimentos foram implementados em Python 3, com as bibliotecas scikit-learn [Pedregosa et al. 2011], pandas e matplotlib. O código foi desenvolvido em notebooks Jupyter e estruturado para execução tanto no Google Colab quanto em ambiente local (VS Code), com detecção automática do ambiente na célula de inicialização. A divisão entre os dois notebooks segue a separação natural do pipeline: o notebook `01_training_evaluation.ipynb` cobre o treinamento e avaliação baseline, enquanto o `02_robustness_analysis.ipynb` abrange a validação cruzada, curvas de aprendizado e análise de erros. O repositório está disponível publicamente em `https://github.com/ROMAUSKI/tcc-analise-sentimento`.

5. Resultados e Discussão

Esta seção apresenta os resultados obtidos nas três etapas de avaliação descritas na Metodologia: avaliação no conjunto de teste, validação cruzada estratificada e análise de erros. Os resultados são discutidos à luz das perguntas de pesquisa do trabalho.

5.1. Avaliação no Conjunto de Teste

A Tabela 2 apresenta as métricas de desempenho dos três classificadores no conjunto de teste (360 amostras, 20% do dataset). O Naive Bayes e o SVM Linear obtiveram acurácia idêntica de 86,11%, enquanto a Regressão Logística ficou ligeiramente abaixo, com 83,61%. O F1-Score ponderado acompanha o mesmo padrão, com valores de 86,13% para o Naive Bayes, 86,09% para o SVM Linear e 83,54% para a Regressão Logística.

Table 2. Métricas de desempenho no conjunto de teste (80/20, seed=42).

Modelo	Acurácia (%)	Precisão (%)	Recall (%)	F1-Score (%)
Naive Bayes	86,11	86,19	86,11	86,13
SVM Linear	86,11	86,21	86,11	86,09
Reg. Logística	83,61	83,80	83,61	83,54

Esse resultado é interessante porque contraria a expectativa teórica de que classificadores discriminativos (como a Regressão Logística) tendem a superar o Naive Bayes quando há dados suficientes [Pang et al. 2002]. Uma possível explicação é que os dados sintéticos gerados por LLMs possuem uma distribuição de vocabulário mais regular e previsível do que dados reais, o que favorece a suposição de independência condicional do Naive Bayes. Cada LLM tende a utilizar um conjunto relativamente estável de palavras-chave para cada classe de sentimento, e essa regularidade é exatamente o tipo de padrão que o Naive Bayes captura de forma eficiente com TF-IDF.

A Figura 1 apresenta a matriz de confusão do Naive Bayes. As maiores confusões ocorrem entre as classes Positiva e Negativa, o que sugere que certas construções linguísticas — como negações compostas ou vocabulário ambíguo — dificultam a distinção de polaridade por classificadores baseados em frequência de termos.

Figure 1. Matriz de confusão do Naive Bayes no conjunto de teste.

5.2. Validação Cruzada

Para obter estimativas mais robustas do desempenho, os três modelos foram avaliados com validação cruzada estratificada usando k=5 e k=10 folds. A Tabela 3 apresenta os resultados em termos de F1-Score médio e desvio padrão.

Table 3. F1-Score (%) com validação cruzada estratificada.

Modelo	k	Acurácia (%)	F1-Score (%)
Naive Bayes	5	88,82 ± 1,83	88,86 ± 1,82
Naive Bayes	10	89,60 ± 2,16	89,63 ± 2,15
Reg. Logística	5	87,32 ± 1,43	87,31 ± 1,42
Reg. Logística	10	88,04 ± 2,42	88,02 ± 2,44
SVM Linear	5	88,88 ± 1,33	88,88 ± 1,33
SVM Linear	10	89,10 ± 2,49	89,10 ± 2,51

Com validação cruzada, os três modelos apresentam desempenho superior ao observado no split simples, o que indica que a partição fixa de 80/20 pode não ser a mais representativa. O Naive Bayes atinge o maior F1-Score médio com k=10 (89,63%), seguido de perto pelo SVM Linear (89,10%). A Regressão Logística, embora com desempenho inferior, ainda supera 88% com k=10. O desvio padrão do SVM com k=10 (2,51%) é o maior entre os modelos, sugerindo uma sensibilidade um pouco maior à composição dos folds.

A Figura 2 apresenta a distribuição dos scores ao longo dos folds, permitindo visualizar a dispersão e a presença de outliers. O SVM Linear apresenta a menor mediana de dispersão com k=5 (desvio de 1,33%), enquanto o Naive Bayes mostra o comportamento mais estável entre as duas configurações de k.

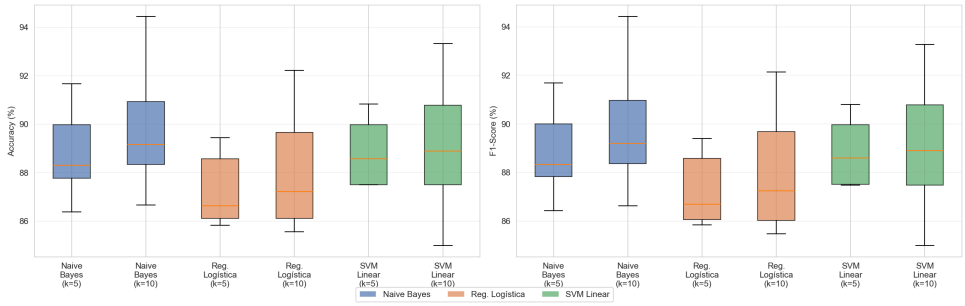

Figure 2. Distribuição dos scores de validação cruzada (k=5 e k=10) para os três modelos.

5.3. Curvas de Aprendizado

As curvas de aprendizado foram geradas variando a fração de dados de treino de 10% a 100%, com validação cruzada de 5 folds em cada ponto. A Figura 3 mostra a curva do Naive Bayes: o modelo atinge desempenho próximo ao platô com apenas 50–60% dos dados de treino, o que indica que o volume atual de dados é suficiente para esse classificador. O gap entre a curva de treino e a de validação é pequeno, sugerindo baixo overfitting.

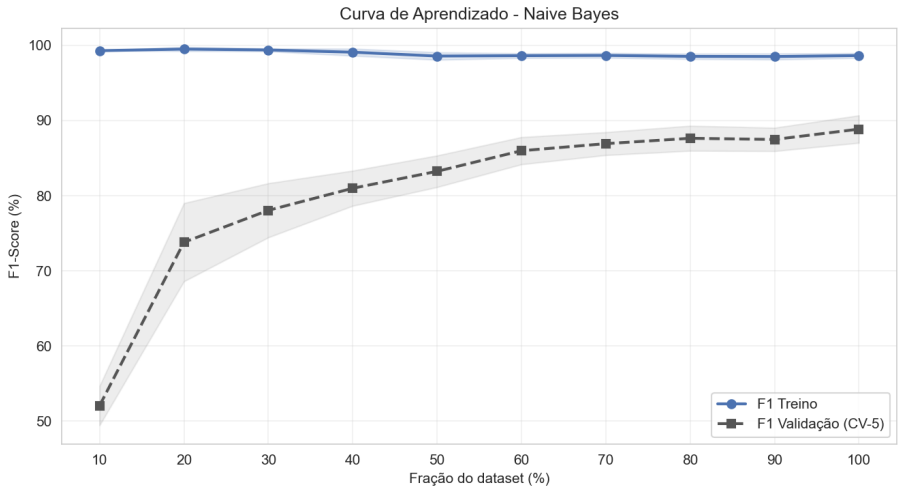

Figure 3. Curva de aprendizado do Naive Bayes (F1-Score vs. fração do dataset).

A Regressão Logística e o SVM Linear apresentam um padrão similar, mas convergem mais lentamente — o platô de validação é atingido com aproximadamente 70–80% dos dados. Esse comportamento é esperado, já que classificadores discriminativos como a Regressão Logística e o SVM tendem a se beneficiar mais de volumes maiores de dados para estimar a fronteira de decisão. O gap entre treino e validação é levemente maior nesses modelos, o que indica um ajuste mais justo aos dados de treino sem configurar overfitting severo.

5.4. Análise de Erros

Para compreender os padrões de erro, as predições incorretas do Naive Bayes no conjunto de teste foram analisadas em detalhe. Dos 360 exemplos de teste, 50 foram classificados incorretamente (13,9% de taxa de erro). A análise revelou dois padrões principais de confusão.

O primeiro e mais frequente padrão é a confusão entre as classes Positiva e Negativa. Das 50 classificações incorretas, 24 envolvem inversão de polaridade — 13 frases negativas classificadas como positivas e 11 positivas classificadas como negativas. Esse tipo de erro está associado a construções linguísticas que contêm tanto palavras positivas quanto negativas na mesma frase, como "os efeitos especiais são muito ruins para a época", onde o termo "especiais" tem conotação positiva isoladamente, mas o contexto é negativo. Classificadores baseados em frequência de termos, como o Naive Bayes com TF-IDF, não capturam relações de dependência entre palavras, o que dificulta o tratamento de negações compostas e construções irônicas.

O segundo padrão envolve frases neutras classificadas com polaridade. Frases como "O roteiro de Pulp Fiction é conhecido por sua narrativa não linear" contêm termos que, em outros contextos, carregam sentimento ("conhecido", "não linear"), mas neste caso são puramente descritivos. A fronteira entre neutralidade e opinião é particularmente difícil para classificadores que operam no nível lexical.

A análise por fonte geradora revelou diferenças relevantes na taxa de erro: frases do ChatGPT apresentaram a menor taxa de erros (9,9%), seguidas por Claude (14,1%) e Gemini (17,4%). Esse resultado sugere que o ChatGPT gera frases com polaridade

mais explícita e menos ambígua, enquanto o Gemini produz textos com vocabulário mais descritivo que, em alguns casos, dificulta a distinção automática de sentimento. A Figura 4 apresenta a distribuição de erros por fonte e a heatmap de confusões entre classes.

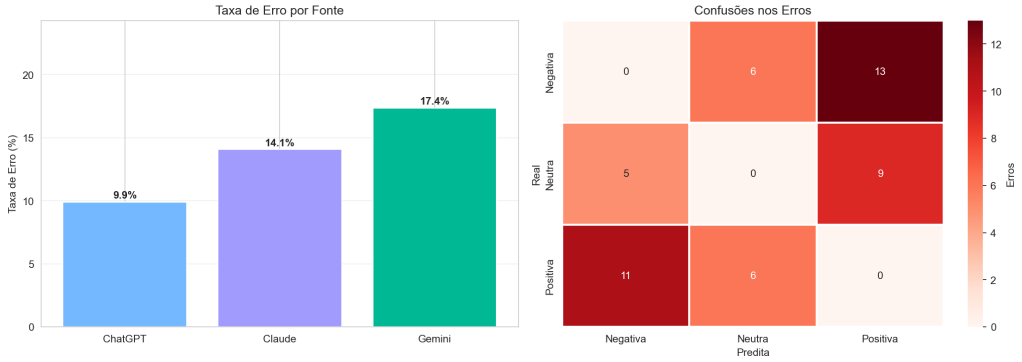

Figure 4. Distribuição de erros por fonte geradora e heatmap de confusões entre classes.

5.5. Discussão Geral

Os resultados respondem às duas perguntas de pesquisa do trabalho. Em relação à primeira pergunta — qual a assertividade dos modelos treinados com dados sintéticos —, os três classificadores atingem F1-Score entre 86% e 89% dependendo do protocolo de avaliação, o que pode ser considerado um desempenho satisfatório para modelos baseline treinados exclusivamente com dados gerados por LLMs. Esses valores são comparáveis aos reportados em trabalhos que utilizam dados reais para tarefas similares em português [Kansaon and Moro 2019, de Souza et al. 2021].

Em relação à segunda pergunta — se a classificação é coerente entre os diferentes LLMs geradores —, a análise de erros mostra que há diferenças relevantes: o ChatGPT gera dados com menor taxa de ambiguidade (9,9% de erro), enquanto o Gemini produz frases mais propensas a confusão (17,4%). Essa variação indica que a escolha do LLM gerador impacta a qualidade do dataset e, consequentemente, o desempenho dos classificadores. A combinação de múltiplas fontes, como adotada neste trabalho, tende a mitigar o viés individual de cada gerador.

6. Conclusão

References

Araujo, G. d., de Melo, T., and Figueiredo, C. M. S. (2024). Is ChatGPT an effective solver of sentiment analysis tasks in Portuguese? A preliminary study. In *Proceedings of the 16th International Conference on Computational Processing of Portuguese (PROPOR 2024)*, pages 13–21, Santiago de Compostela, Espanha. Association for Computational Linguistics.

de Souza, V. A., de Souza, É. F., and Meinerz, G. V. (2021). Análise de sentimento em tempo real. *Brazilian Journal of Development*, 7(1):11084–11091.

Hellwig, N. C., Fehle, J., and Wolff, C. (2025). Exploring large language models for the generation of synthetic training samples for aspect-based sentiment analysis in low resource settings. *Expert Systems with Applications*, 261:125514.

Jurafsky, D. and Martin, J. H. (2025). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*. Stanford University, 3rd edition. Online manuscript released August 24, 2025.

Kansaon, D. J. and Moro, S. (2019). Análise de sentimentos em tweets em português brasileiro. In *Anais do BrasNAM 2019*. UFMG.

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, pages 1137–1145, Montreal, Canada. Morgan Kaufmann.

Li, Z., Zhu, H., Lu, Z., and Yin, M. (2023). Synthetic data generation with large language models for text classification: Potential and limitations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*.

Liu, R., Wei, J., Liu, F., Si, C., Zhang, Y., Rao, J., Zheng, S., Peng, D., Yang, D., Zhou, D., and Dai, A. M. (2024). Best practices and lessons learned on synthetic data for language models. In *Proceedings of COLM 2024*.

Nadas, M., Diosan, L., and Tomescu, A. (2025). Synthetic data generation using large language models: Advances in text and code. *arXiv preprint arXiv:2503.14023*.

Pang, B., Lee, L., and Vaithyanathan, S. (2002). Thumbs up? sentiment classification using machine learning techniques. pages 79–86.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., VanderPlas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Rossi, R. H. P. S. (2019). *Análise de sentimentos para o auxílio na gestão das Cidades Inteligentes*. Tese de doutorado, Universidade de São Paulo.

Sokolova, M. and Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4):427–437.

Souza, F. and Filho, J. A. (2021). Sentiment analysis on Brazilian Portuguese user reviews. *arXiv preprint arXiv:2112.05459*. Publicado em IEEE LA-CCI 2022.

Zhang, W., Deng, Y., Liu, B., Pan, S., and Bing, L. (2024). Sentiment analysis in the era of large language models: A reality check. In *Findings of the Association for Computational Linguistics: NAACL 2024*, pages 3881–3906, Cidade do México, México.