

Utilização de LLMs para Geração de Bases de Treinamento em Classificação de Sentimento: Uma Análise de Viabilidade Prática

Davi Romauski Meurer¹, Marlon Marcon¹

¹Departamento de Engenharia de Software
Universidade Tecnológica Federal do Paraná (UTFPR) – Dois Vizinhos, PR – Brasil

davimeurer@alunos.utfpr.edu.br, marlonmarcon@utfpr.edu.br

Abstract. *The lack of labeled datasets in Brazilian Portuguese is a very common obstacle for sentiment analysis research. This work evaluates whether synthetic data generated by three LLMs — ChatGPT, Gemini, and Claude — can be used to train classifiers in a real-world scenario. Two synthetic datasets of 1,800 sentences each were built (movies and series, and mobile apps), and five classifiers (Naive Bayes, Logistic Regression, Linear SVM, LSTM, and BERTimbau) were trained and evaluated under five methodological views covering training and testing on synthetic data, training and testing on real data, and synthetic training tested on real data, the latter two under both controlled volume and natural unbalanced distribution. The results show that the synthetic to synthetic scenario reaches 97% macro F1 with BERTimbau, but in the realistic unbalanced cross-domain setting the macro F1 reaches only 43% in the movies and series niche and 56% in the apps niche. This gap persists even when tripling the synthetic training volume, which indicates that the limitation comes from a structural difference in distribution between LLM-generated text and reviews written by real users, and not from data scarcity. The large difference between the two niches suggests that the viability of synthetic data depends on how regular and objective the evaluation domain is.*

Resumo. *A falta de datasets rotulados em português brasileiro é um obstáculo muito comum para pesquisas em análise de sentimento. Este trabalho avalia se dados sintéticos gerados por três LLMs — ChatGPT, Gemini e Claude — podem ser usados para treinar classificadores em um cenário real. Foram construídos dois datasets sintéticos de 1.800 frases cada (filmes e séries, e aplicativos móveis), e foram treinados cinco classificadores (Naive Bayes, Regressão Logística, SVM Linear, LSTM e BERTimbau) avaliados em cinco visões metodológicas que cobrem treino e teste em dados sintéticos, treino e teste em dados reais e treino sintético testado em dados reais, estas duas últimas tanto em volume controlado quanto em distribuição natural desbalanceada. Os resultados mostram que o cenário sintético para sintético chega a 97% de F1-macro com BERTimbau, mas no cenário cross-domain desbalanceado mais realista o F1-macro fica em apenas 43% no nicho de filmes e séries e 56% no nicho de aplicativos. Esse gap se mantém mesmo triplicando o volume de treino sintético, o que indica que a limitação vem de uma diferença estrutural na distribuição entre texto gerado por LLMs e reviews escritas por usuários reais, e não da*

escassez de dados. A diferença grande entre os dois nichos sugere que a viabilidade dos dados sintéticos depende de quão regular e objetivo é o domínio de avaliação.

1. Introdução

A análise de sentimento é uma tarefa de classificação de texto que busca identificar a polaridade — positiva, negativa ou neutra — de uma opinião dita em linguagem natural. Tem uso direto em mineração de opinião, monitoramento de redes sociais e análise de feedback de produtos e serviços [Jurafsky and Martin 2025]. Treinar modelos para essa tarefa, no entanto, depende de datasets rotulados de qualidade, e a construção manual desses datasets é cara, demorada e suscetível a inconsistências. Esse problema é ainda mais notado quando vamos para o cenário do idioma português brasileiro, onde a disponibilidade de recursos linguísticos anotados é bem menor do que no inglês [Souza and Filho 2021].

Uma maneira que vem sendo cada vez mais cogitada e chamando atenção é o uso de grandes modelos de linguagem artificial (LLMs) como geradores de dados sintéticos de treinamento [Liu et al. 2024, Nadas et al. 2025]. Modelos como ChatGPT, Gemini e Claude conseguem produzir textos coerentes e contextualmente adequados em português, o que abre a possibilidade de criar datasets rotulados sem depender de inserção ou classificação humana em plataformas de avaliação. Trabalhos recentes já investigaram essa abordagem para classificação de texto e análise de sentimento baseada em aspectos, com resultados promissores em cenários de poucos recursos [Li et al. 2023, Hellwig et al. 2025].

Este trabalho investiga três perguntas relacionadas. A primeira é qual a assertividade de classificadores treinados exclusivamente com dados sintéticos. A segunda é se há coerência entre os dados produzidos por diferentes LLMs geradores. A terceira é se modelos treinados em dados sintéticos têm um bom resultado ao serem submetidos em dados reais (avaliação *cross-domain*). Para responder essas perguntas, foram construídos dois datasets sintéticos de 1.800 frases cada, em dois nichos distintos: críticas de filmes e séries (com base no UTLC-Movies) e reviews de aplicativos móveis (com base no UTLC-Apps). Cinco classificadores foram avaliados sob cinco visões metodológicas, cobrindo desde modelos lineares com TF-IDF (Naive Bayes, Regressão Logística e SVM Linear) até arquiteturas neurais (LSTM e BERTimbau).

Este artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica. A Seção 3 revisa trabalhos relacionados. A Seção 4 descreve a metodologia, incluindo a definição das cinco visões e os dois nichos. A Seção 5 apresenta os resultados organizados em três blocos: domínio sintético, domínio real e *cross-domain*. Por fim, a Seção 6 traz as conclusões.

2. Fundamentação Teórica

A análise de sentimento pode ser considerada como um problema de classificação supervisionada, onde o objetivo é atribuir uma classe (Positiva, Negativa ou Neutra) a cada instância textual [Jurafsky and Martin 2025]. Neste trabalho a classificação é feita no nível da frase, ou seja, cada frase recebe uma única classe. Um dos desafios conhecidos da tarefa é o tratamento de negações compostas e ambiguidades — frases como “não gostei nada desse filme” têm polaridade oposta ao que seria esperado pela presença isolada do

verbo “gostar”, e esse tipo de construção tende a causar erros em classificadores baseados apenas em frequência de termos.

Para que algoritmos processem texto, é preciso converter as frases em representações numéricas. O TF-IDF (*Term Frequency–Inverse Document Frequency*) representa cada documento como um vetor que ajusta as contagens de palavras pela frequência inversa delas no corpus, penalizando termos muito frequentes — como preposições — que aparecem em quase todos os documentos [Rossi 2019]. Os classificadores clássicos utilizados neste trabalho operam sobre essa representação: o Naive Bayes Multinomial é um modelo probabilístico que assume independência condicional entre os atributos, a Regressão Logística é um classificador discriminativo que aprende diretamente a fronteira de decisão, e o SVM Linear busca a superfície de separação (hiperplano) que fica o mais distante possível dos exemplos de cada classe, maximizando a margem entre elas [Pang et al. 2002].

Para os modelos avançados, o trabalho utiliza dois paradigmas distintos. O LSTM (*Long Short-Term Memory*) é uma rede neural recorrente que processa as palavras em sequência, com embeddings aprendidos do zero a partir do dataset de treino. Já o BERTimbau [Souza and Filho 2021] é um modelo BERT pré-treinado em 2,7 bilhões de palavras de português brasileiro, baseado na arquitetura Transformer. O modelo foi pré-treinado pela equipe da NeuralMind/USP em tarefas de *Masked Language Modeling*, ou seja, ele não foi originalmente treinado para análise de sentimento. Neste trabalho, o BERTimbau é adaptado para a tarefa via fine-tuning: as cabeças de predição do pré-treino são removidas e uma camada linear de classificação é adicionada e treinada com os dados sintéticos.

Para avaliar os classificadores, são utilizadas cinco métricas: acurácia (proporção de classificações corretas sobre o total), precisão (proporção de verdadeiros positivos entre as predições positivas), recall (proporção de verdadeiros positivos entre os exemplos reais de uma classe), F1-Score weighted (média harmônica de precisão e recall ponderada pelo número de amostras por classe) e F1-Score macro (média harmônica simples por classe). A diferença entre F1-weighted e F1-macro é especialmente importante em datasets desbalanceados — o weighted tende a favorecer a classe majoritária, enquanto o macro força o modelo a apresentar bom desempenho em todas as classes igualmente. Por isso este trabalho adota o F1-macro como métrica principal nas comparações, já que ele reflete melhor o desempenho real quando as classes estão desbalanceadas. Vale lembrar ainda que, em classificação multiclasse, o recall ponderado coincide com a acurácia, então a tabela de métricas detalhadas reporta acurácia, precisão e F1-macro, sem repetir o recall.

3. Trabalhos Relacionados

Esta seção revisa trabalhos que abordam análise de sentimento com aprendizado de máquina, com foco em aplicações em língua portuguesa e no uso de dados sintéticos para treinamento de classificadores.

3.1. Análise de Sentimento com Aprendizado de Máquina

Diversos trabalhos aplicaram aprendizado de máquina à análise de sentimento, sempre treinando os classificadores com dados reais rotulados manualmente. O estudo pioneiro

de [Pang et al. 2002] mostrou que classificadores como Naive Bayes e SVM superaram os métodos baseados em regras — abordagens que dependem de listas de palavras com polaridade fixa e regras definidas manualmente —, atingindo cerca de 82,9% de acurácia em resenhas do IMDb. A partir desse trabalho, a análise de sentimento passou a ser tratada como um problema de classificação supervisionada, em que o modelo aprende os padrões a partir dos exemplos em vez de seguir regras escritas por humanos.

Em português brasileiro, os trabalhos seguem essa mesma linha e ajudam a situar a faixa de desempenho esperada para a tarefa. [Kansaon and Moro 2019], [de Souza et al. 2021] e [Rossi 2019] combinaram TF-IDF com classificadores clássicos sobre datasets reais e alcançaram acurácias entre 76% e 85%, variando conforme o domínio e a técnica. [Rossi 2019] mostrou ainda que o TF-IDF tende a apresentar ganhos consistentes sobre representações mais simples como o Bag-of-Words, o que justifica sua adoção como vetorização padrão neste trabalho. Todos esses estudos têm um ponto em comum: dependem de bases reais anotadas por humanos. É justamente essa dependência que [Souza and Filho 2021] apontam ao unificarem cinco datasets em português e mostrarem a escassez de recursos anotados para o idioma — a lacuna que motiva a geração de dados sintéticos investigada neste trabalho.

3.2. Dados Sintéticos e LLMs para Geração de Dados de Treinamento

A utilização de dados sintéticos gerados por LLMs para treinamento de modelos é uma área recente. [Zhang et al. 2024] avaliaram o desempenho de LLMs em tarefas de análise de sentimento e indicaram que os modelos vão bem em classificação simples de polaridade, mas ficam atrás em tarefas que exigem compreensão mais profunda como detecção de ironia. [Hellwig et al. 2025] usaram GPT-3.5-turbo e Llama-3-70B para gerar dados anotados para análise baseada em aspectos em cenários de poucos recursos, e mostraram que mesmo pequenas quantidades de dados sintéticos podem complementar datasets escassos. [Li et al. 2023] avaliaram a geração de dados com GPT-3.5-Turbo para classificação de texto e reportaram que a efetividade varia conforme a subjetividade da tarefa.

Do ponto de vista metodológico, [Liu et al. 2024] compilaram boas práticas para uso de dados sintéticos no treinamento de modelos de linguagem, incluindo técnicas de filtragem e refinamento iterativo, além de discutir riscos como amplificação de viés. [Nadas et al. 2025] apresentaram recentemente uma revisão de literatura sobre o tema e destacaram que a abordagem é especialmente promissora para tarefas com poucos recursos em idiomas que não o inglês. [Araujo et al. 2024] investigaram especificamente as capacidades do ChatGPT para análise de sentimento zero-shot em português brasileiro e demonstraram que o modelo se destaca na determinação de polaridade.

3.3. Posicionamento deste Trabalho

A maioria dos trabalhos revisados usa os LLMs como classificadores diretos — entregando a frase e pedindo a classe no mesmo momento, ou seja, sem nenhum exemplo (zero-shot) ou com poucos exemplos no próprio prompt (few-shot) — e não como geradores de dados de treinamento para modelos próprios. Além disso, a maior parte foca no inglês e usa um único LLM como fonte. Este trabalho se diferencia em quatro aspectos: utiliza dados 100% sintéticos gerados por três LLMs distintos (ChatGPT, Gemini e Claude), foca em português brasileiro, avalia explicitamente o *cross-domain* comparando

treino sintético com teste em dados reais, e analisa dois nichos diferentes (filmes e séries, e aplicativos móveis) para entender em que contextos a abordagem é mais ou menos viável.

4. Metodologia

Esta seção descreve o pipeline completo do trabalho, desde a definição das classes e geração dos datasets sintéticos até o protocolo de avaliação. A Seção 4.4 introduz as cinco visões metodológicas que estruturam toda a análise dos resultados.

O desenho metodológico parte de quatro decisões que orientam o restante desta seção. A primeira é gerar dados sintéticos com três LLMs distintos (ChatGPT, Gemini e Claude) em vez de usar um único modelo, de forma a reduzir o viés de geração associado a uma só fonte. A segunda é usar os LLMs como geradores de dados de treinamento, e não como classificadores diretos sem exemplos (*zero-shot*) ou com poucos exemplos no próprio prompt (*few-shot*), que é a abordagem mais comum nos trabalhos revisados. A terceira é focar em português brasileiro, idioma com menos recursos anotados disponíveis. A quarta é avaliar explicitamente o cenário *cross-domain*, treinando com dados sintéticos e testando em reviews reais, e fazer isso em dois nichos diferentes (filmes e séries, e aplicativos móveis) para entender em que contextos a abordagem se aproxima mais ou menos da viabilidade prática. As subseções a seguir detalham as escolhas de classes, datasets, modelos e protocolo de avaliação que decorrem desses quatro pontos.

4.1. Definição das Classes de Sentimento

Antes de gerar os dados, as três classes de sentimento foram definidas explicitamente para que os prompts enviados aos LLMs fossem precisos o suficiente. A classe Positiva contempla textos que expressam satisfação, admiração ou recomendação. A classe Negativa abrange insatisfação, desapontamento ou desaprovação. A classe Neutra compreende textos com informações factuais — sinopses, descrição técnica, dados objetivos — sem emitir juízo de valor.

4.2. Construção dos Datasets Sintéticos

Os datasets foram construídos a partir de dados gerados por três LLMs: ChatGPT (OpenAI), Gemini (Google) e Claude (Anthropic). A escolha por múltiplos modelos teve como objetivo reduzir o viés de geração associado a uma única fonte. Para cada LLM foram solicitadas 200 frases por classe via prompts padronizados enviados manualmente pelas interfaces web, totalizando 1.800 frases por nicho (3 LLMs $\times$ 3 classes $\times$ 200 frases).

O trabalho utiliza dois nichos: filmes e séries (com referência ao UTLC-Movies para os dados reais) e aplicativos móveis (com referência ao UTLC-Apps). Os prompts são isomorfos entre os dois nichos — a única diferença é a substituição de “filmes e séries” por “aplicativos móveis” e “espectador” por “usuário”, mantendo o resto idêntico. Essa decisão garante que diferenças observadas nos resultados possam ser atribuídas ao nicho e não ao prompt.

A Tabela 1 mostra o comprimento médio das frases por LLM em cada nicho. ChatGPT é consistente nos dois nichos, com média próxima de 50 caracteres. Claude se adapta ao domínio: 95 caracteres em filmes e séries (frases mais narrativas) e 66 em apps (mais técnicas). Gemini fica entre os dois em filmes e séries, e próximo do Claude em apps. A Figura 1 apresenta a distribuição completa.

Tabela 1. Comprimento médio das frases sintéticas por LLM e nicho (caracteres).

Nicho	ChatGPT	Claude	Gemini
Filmes	50	95	61
Apps	51	66	67




Figura 1. Boxplot do comprimento das frases sintéticas por LLM gerador em cada nicho.

O diagrama de caixa (*boxplot*) da Figura 1 permite enxergar não só a média, mas a dispersão de cada LLM em cada nicho. ChatGPT aparece com caixas estreitas nos dois nichos, o que indica que ele tende a manter um padrão de comprimento bem regular independentemente do contexto pedido no prompt. Claude é o oposto em filmes e séries — caixa larga, com frases curtas e longas convivendo no mesmo conjunto — e fica visivelmente mais contido em apps, onde a tarefa é mais objetiva. Gemini ocupa uma faixa intermediária, mas com dispersão maior em apps do que em filmes e séries.

Esse padrão sugere que a regularidade do texto sintético depende tanto do LLM quanto do nicho. Em apps, que pedem frases mais técnicas e diretas, os três geradores tendem a se aproximar; em filmes e séries, que admitem narrativa, Claude se distancia dos outros dois. Essa diferença de estilo dentro do conjunto sintético é uma das hipóteses que ajudam a explicar por que o desempenho *cross-domain* muda tanto de um nicho para o outro nos resultados discutidos na Seção 5.

4.3. Dados Reais para Validação Cross-Domain

Para os experimentos *cross-domain*, foram utilizados subconjuntos do dataset `ptbr-sentiment-analysis-datasets` [Souza and Filho 2021] disponível no Kaggle. Cada nicho usou seu arquivo correspondente (`utlc_movies.csv` e `utlc_apps.csv`), com aproximadamente 100 mil reviews por nicho carregadas via `kagglehub`. O dataset original traz a coluna `rating` com notas de 1 a 5, que foi mapeada para as três classes do trabalho: ratings 4 e 5 viraram Positiva, 1 e 2 viraram Negativa e 3 virou Neutra. A distribuição natural após o mapeamento ficou bastante desbalanceada — em filmes e séries, 71% Positiva, 20% Neutra e 9% Negativa; em apps, 72% Positiva, 21% Negativa e 7% Neutra.

4.4. As Cinco Visões Metodológicas

A análise é estruturada em cinco visões que combinam a fonte do treino (sintético ou real), a fonte do teste (sintético ou real) e o regime de volume (controlado em 600 frases

por classe ou natural desbalanceado). A Tabela 2 resume a configuração de cada uma.

Tabela 2. Configuração das cinco visões metodológicas.

Visão	Treino	Teste	Volume
V1	Sintético	Sintético	600/classe (controlado)
V2	Real	Real	600/classe (controlado)
V3	Sintético	Real	600/classe (mesmo test set do V2)
V4	Real	Real	Natural desbalanceado (100k total)
V5	Sintético	Real	Sint. controlado, real desbalanceado (mesmo test set do V4)

A escolha por usar o mesmo conjunto de teste em V2 e V3 é uma decisão de controle experimental: como o conjunto de teste é idêntico, a única variável que muda entre as duas visões é a fonte do treino. O mesmo vale para V4 e V5. Esse desenho permite isolar o efeito do uso de dados sintéticos no desempenho final.

4.5. Modelos de Classificação

Foram avaliados cinco classificadores. Os três clássicos foram implementados via `scikit-learn` [Pedregosa et al. 2011] com hiperparâmetros padrão: `Naive Bayes Multinomial` (`MultinomialNB()`), `Regressão Logística` (`LogisticRegression(max_iter=1000)`) e `SVM Linear` (`LinearSVC(max_iter=5000)`). O LSTM foi implementado em `PyTorch` com uma camada recorrente de 128 unidades, embeddings aprendidos do zero (dimensão 128), dropout de 0,3 e otimizador `AdamW` com taxa de aprendizado $1e-3$. O `BERTimbau` [Souza and Filho 2021] foi utilizado em sua versão base (`neuralmind/bert-base-portuguese-cased`), com fine-tuning por 3 epochs, batch size de 16, taxa de aprendizado $2e-5$ e tamanho máximo de sequência de 128 tokens.

Para todas as visões usou-se semente aleatória fixa (`random_state=42`) para garantir reprodutibilidade. Os experimentos com BERT e LSTM foram executados em GPU NVIDIA T4 via Google Colab, com tempo total de aproximadamente 50 minutos para o nicho de filmes e séries, e 35 minutos para o nicho de apps.

4.6. Pré-processamento e Vetorização

Os textos sintéticos passaram por quatro operações de limpeza: conversão para minúsculas, remoção de pontuação e caracteres especiais, normalização de espaços e remoção de eventuais duplicatas. Para os modelos clássicos, a vetorização foi feita com `TfidfVectorizer` do `scikit-learn` (parâmetros padrão, sem remoção explícita de stopwords). Para o LSTM, a tokenização foi por palavra (split em espaço) com vocabulário construído a partir do treino de cada visão. Para o `BERTimbau`, foi usado o tokenizer próprio do modelo (`AutoTokenizer.from_pretrained`).

4.7. Ambiente Experimental

Os experimentos foram implementados em Python 3, com `scikit-learn` [Pedregosa et al. 2011], `pandas`, `matplotlib`, `PyTorch` e `Hugging Face Transformers`. O código foi estruturado em notebooks Jupyter com detecção automática de ambiente (Google Colab ou execução local). O repositório está disponível em <https://github.com/ROMAUSKI/tcc-analise-sentimento>.

5. Resultados e Discussão

Esta seção apresenta os resultados organizados em três blocos principais: o desempenho no domínio sintético (V1), no domínio real (V2 e V4) e no *cross-domain* entre os dois (V3 e V5). Em seguida são apresentados o comparativo entre os dois nichos e a validação cruzada do dataset original. Os valores reportados nas tabelas a seguir referem-se ao F1-Score macro.

5.1. Domínio Sintético (V1)

A primeira visão avalia os modelos treinados e testados em dados sintéticos do mesmo nicho. A Tabela 3 mostra que os cinco modelos atingem F1-Score acima de 80% em ambos os nichos, e o BERTimbau alcança 97% em filmes e séries, e 97% em apps. Esse resultado mostra que os dados sintéticos gerados pelos LLMs são internamente coerentes — quando o modelo é avaliado em frases do mesmo tipo que viu no treino, a classificação é praticamente perfeita.

Tabela 3. F1-Score macro (%) na visão V1: Sintético → Sintético.

Modelo	Filmes	Apps
Naive Bayes	88,07	88,82
Regressão Logística	86,93	89,69
SVM Linear	88,33	91,07
LSTM	81,40	85,22
BERTimbau	97,49	97,22

Esse resultado, no entanto, precisa ser lido com cautela. O alto desempenho em V1 não significa que os classificadores funcionariam bem em produção — significa apenas que os modelos aprenderam o padrão dos dados sintéticos, que é mais regular e previsível do que o de avaliações reais. As visões V3 e V5, apresentadas mais adiante, é que realmente testam se esse aprendizado se transfere.

5.2. Domínio Real (V2 e V4)

As visões V2 e V4 usam dados reais tanto no treino quanto no teste, com regimes de volume diferentes. V2 é controlada (600 frases por classe) e V4 usa as cerca de 100 mil reviews reais carregadas por nicho, mantendo a distribuição natural desbalanceada. A Tabela 4 apresenta os resultados.

Tabela 4. F1-Score macro (%) nas visões V2 (controlada) e V4 (desbalanceada).

Modelo	V2		V4	
	Filmes	Apps	Filmes	Apps
Naive Bayes	52,10	62,50	38,48	54,83
Regressão Logística	54,45	61,18	52,05	58,44
SVM Linear	54,80	58,16	51,92	57,35
LSTM	39,23	56,01	54,89	63,11
BERTimbau	60,42	66,84	62,29	66,59

V2 mostra que mesmo com dados reais, classificar reviews em três classes com apenas 600 amostras por classe não é trivial — os modelos clássicos ficam entre 52 e 62%

e o BERTimbau alcança 60-67%. Já a V4 usa as cerca de 100 mil reviews reais, e aqui a escolha da métrica faz diferença. Se olhássemos o F1-weighted, os modelos apareceriam na faixa de 64 a 86%, o que pareceria um ótimo resultado. Mas esse valor é inflado pelo desbalanceamento natural — a classe Positiva domina 71-72% das amostras, então o modelo acerta muito nela e erra mais nas minoritárias. O F1-macro, que dá o mesmo peso a cada classe, mostra o cenário real: fica entre 38 e 67%. É por isso que adotamos o macro como métrica principal nas tabelas.

5.3. Cross-Domain (V3 e V5)

As visões V3 e V5 são as mais relevantes do trabalho porque medem se os modelos de classificadores treinados com dados sintéticos são aplicáveis a reviews reais. V3 testa no conjunto controlado (o mesmo do V2) e V5 testa no conjunto desbalanceado (o mesmo do V4). Antes de apresentar os números, a Tabela 5 ilustra o tipo de diferença estrutural que aparece entre o texto sintético e o texto real — frases sintéticas tendem a ser bem formadas, com polaridade explícita e vocabulário regular, enquanto reviews reais trazem informalidade, abreviações, erros de digitação, gírias e pontuação não-convencional.

Tabela 5. Exemplos lado a lado de frases sintéticas (Claude) e reais (UTLC-Movies) por classe. O contraste estrutural ajuda a entender o reality gap quantificado adiante.

Classe	Sintética (Claude)	Real (UTLC-Movies)
Positiva	“Nunca vi atuações tão intensas e verdadeiras, este filme merece todos os prêmios possíveis.”	“Estou sem xão sem ar sem vida PQP q filme”
Negativa	“A história é completamente previsível e sem originalidade, consegui adivinhar o final nos primeiros dez minutos.”	“Horível com péssimas interpretações.”
Neutra	“O filme tem duração de duas horas e quinze minutos e foi lançado nos cinemas em março.”	“é bem interessante! mais ainda sim não deixa de ser sessão da tarde”

Para entender onde o modelo treinado em dados sintéticos se perde quando enfrenta reviews reais, a Figura 2 apresenta a matriz de confusão do SVM Linear em V3 (filmes e séries). A classe Neutra é a mais sacrificada — apenas 108 das 600 frases neutras reais foram classificadas corretamente, com 305 sendo confundidas com Negativa e 187 com Positiva. Reviews reais positivas curtas e informais também acabam sendo classificadas como Negativas em quase um terço dos casos. Esse padrão se repete nos demais modelos clássicos e atinge intensidade menor mas similar no BERTimbau.




Figura 2. Matriz de confusão do SVM Linear em V3 (Sintético → Real, filmes e séries, 600 frases por classe no teste). A classe Neutra é a mais sacrificada e há transbordamento entre Positiva e Negativa.

Os números agregados das duas visões *cross-domain* estão na Tabela 6. O tamanho do gap fica imediato: o BERTimbau cai de 97% (V1) para 47% em filmes e séries, e 48% em apps; os modelos clássicos caem para 34-42%. Esse é o reality gap — os classificadores treinados com dados sintéticos não conseguem reproduzir o desempenho de V1 quando o teste vem de avaliações reais. A diferença entre V1 e V3 é de cerca de 50 pontos para o BERTimbau e 50-55 pontos para os modelos clássicos.

Tabela 6. F1-Score macro (%) nas visões V3 e V5: Sintético → Real.

Modelo	V3		V5	
	Filmes	Apps	Filmes	Apps
Naive Bayes	34,75	40,42	32,29	45,02
Regressão Logística	38,77	40,24	32,61	43,04
SVM Linear	36,45	42,17	32,50	43,35
LSTM	34,83	31,66	27,13	36,23
BERTimbau	47,10	48,21	42,62	55,68

A Figura 3 mostra o comparativo lado a lado dos dois nichos, em F1-macro, para todas as visões e todos os modelos. O padrão fica visualmente claro: V1 muito alto, V2 e V4 intermediários, V3 e V5 ruins.




Figura 3. F1-Score macro nas cinco visões para os dois nichos (Filmes e séries / Apps).

Um experimento adicional foi feito para verificar se aumentar o volume de dados sintéticos reduziria o gap. O dataset sintético foi balanceado em duas configurações: 200 frases por classe e 600 frases por classe (triplicando o volume de treino). A Figura 4 mostra o resultado para o nicho de filmes e séries. Em V1 (sintético-sintético) e V2 (real-real) o desempenho sobe com mais dados, como esperado. Mas em V3 (sintético-real) o desempenho fica praticamente igual nas duas configurações. Isso indica que o gap em V3 não vem da escassez de dados sintéticos — vem de uma diferença estrutural na distribuição entre o texto gerado por LLMs e as reviews reais.




Figura 4. Comparação do desempenho em filmes e séries com 200 vs 600 frases sintéticas por classe. Volume não fecha o gap em V3.

Para fechar a análise do *cross-domain*, a Tabela 7 detalha as visões desbalanceadas V4 e V5 com três métricas — acurácia, precisão e F1-macro — nos dois nichos. O

contraste entre a acurácia e o F1-macro é o que mais chama atenção: em V4, vários modelos passam de 70-80% de acurácia mas ficam abaixo de 60% no F1-macro. Isso acontece porque a acurácia é puxada pela classe Positiva, que domina o conjunto real, enquanto o F1-macro cobra acerto em todas as classes igualmente. Comparar a V4 (treino real) com a V5 (treino sintético), usando o mesmo conjunto de teste, deixa explícita a queda ao trocar a fonte do treino.

Um ponto que pode parecer estranho à primeira vista é a precisão ficar acima da acurácia na V5. Isso acontece porque o modelo treinado em dados sintéticos é relativamente preciso quando aposta na classe Positiva, mas erra ao cobrir as classes minoritárias — o que derruba a acurácia e o F1-macro sem afetar tanto a precisão.

Tabela 7. Métricas detalhadas nas visões desbalanceadas V4 (Real → Real) e V5 (Sintético → Real), por nicho.

Modelo	Acurácia	Precisão	F1-macro
<i>Filmes e séries — V4 (Real → Real)</i>			
Naive Bayes	72,71	68,77	38,48
Regressão Logística	74,72	70,99	52,05
SVM Linear	74,40	70,49	51,92
LSTM	73,48	71,37	54,89
BERTimbau	77,88	75,86	62,29
<i>Filmes e séries — V5 (Sintético → Real)</i>			
Naive Bayes	42,42	61,27	32,29
Regressão Logística	39,99	60,34	32,61
SVM Linear	40,19	60,65	32,50
LSTM	37,39	58,76	27,13
BERTimbau	57,16	63,22	42,62
<i>Apps — V4 (Real → Real)</i>			
Naive Bayes	83,99	81,30	54,83
Regressão Logística	85,09	82,40	58,44
SVM Linear	84,59	81,51	57,35
LSTM	84,64	83,25	63,11
BERTimbau	87,17	85,65	66,59
<i>Apps — V5 (Sintético → Real)</i>			
Naive Bayes	65,71	72,79	45,02
Regressão Logística	63,06	70,99	43,04
SVM Linear	62,70	71,60	43,35
LSTM	59,77	59,62	36,23
BERTimbau	82,48	81,13	55,68

5.4. Comparativo entre Nichos

Comparando os dois nichos, apps tende a apresentar desempenho maior do que filmes e séries nas visões com dados reais (V2, V4 e V5); já no domínio sintético (V1) e no *cross-domain* controlado (V3) os dois nichos ficam praticamente empatados. A diferença mais marcante está em V5: o BERTimbau alcança 55,68% de F1-macro em apps contra 42,62% em filmes e séries — uma diferença de 13 pontos. Mesmo nos modelos clássicos a diferença em V5 fica entre 10 e 13 pontos a favor de apps.

Essa diferença pode ser explicada pela natureza dos dois nichos. Reviews de aplicativos tendem a ser mais objetivas e técnicas — o usuário reclama de coisas concretas

como travamentos, consumo de bateria ou anúncios excessivos. Esse tipo de vocabulário é mais regular e está mais próximo do que os LLMs geram naturalmente. Reviews de filmes e séries têm narrativa, comparações com outras obras, ironia e apreciação subjetiva — uma linguagem mais distante do que o LLM produz sem instruções específicas. A consequência prática é que a viabilidade de treinar com dados sintéticos depende do nicho: pode funcionar melhor em domínios objetivos de avaliação de produto e funciona pior em domínios com linguagem mais elaborada.

5.5. Validação Cruzada

Como complemento, foi realizada a validação cruzada estratificada com $k=5$ e $k=10$ sobre o dataset sintético inteiro de filmes e séries (1.800 frases) para os modelos clássicos. A Tabela 8 apresenta os resultados.

Tabela 8. F1-Score (%) com validação cruzada estratificada no dataset sintético de filmes e séries.

Modelo	k	Acurácia (%)	F1-Score (%)
Naive Bayes	5	$88,82 \pm 1,83$	$88,86 \pm 1,82$
Naive Bayes	10	$89,50 \pm 2,15$	$89,53 \pm 2,15$
Reg. Logística	5	$87,32 \pm 1,43$	$87,31 \pm 1,42$
Reg. Logística	10	$88,04 \pm 2,42$	$88,02 \pm 2,44$
SVM Linear	5	$88,88 \pm 1,33$	$88,88 \pm 1,33$
SVM Linear	10	$89,10 \pm 2,49$	$89,10 \pm 2,51$

Os desvios padrão abaixo de 2,5% indicam estabilidade nas estimativas — os classificadores não dependem de uma divisão particular do dataset para alcançar esses resultados. Esses valores correspondem ao cenário sintético-sintético, equivalente à visão V1, e reforçam o que foi observado nessa visão: os modelos aprendem bem o padrão dos dados sintéticos, mas isso não se traduz em bom desempenho *cross-domain*.

6. Conclusão

Os resultados deste trabalho mostram que dados sintéticos gerados por LLMs não constituem uma alternativa viável para treinar classificadores de sentimento destinados a uso prático. Modelos treinados exclusivamente em frases sintéticas e avaliados em reviews reais atingem, no cenário desbalanceado mais realista, apenas 43% de F1-macro no nicho de filmes e séries e 56% no nicho de aplicativos, valores muito abaixo do patamar mínimo aceitável para qualquer aplicação que exija confiabilidade. Esse desempenho aparece de forma consistente nas cinco visões metodológicas testadas e nos cinco modelos avaliados, o que indica que a limitação não decorre de uma escolha pontual de classificador ou hiperparâmetro, mas sim de uma diferença estrutural entre o texto gerado por LLMs e as avaliações escritas por usuários reais.

A análise comparativa entre volumes de 200 e 600 frases por classe reforça essa interpretação. Triplicar a quantidade de dados sintéticos no treino mantém o desempenho *cross-domain* praticamente inalterado, o que mostra que a limitação observada não vem da escassez de dados, e sim da regularidade do vocabulário, da polaridade explícita e da baixa incidência de construções complexas como negação composta e ironia nas frases sintéticas. Modelos contextuais pré-treinados como o BERTimbau atenuam parte do

problema, recuperando entre seis e onze pontos percentuais sobre os classificadores baseados em TF-IDF, mas mesmo essa melhoria não chega a níveis suficientes para uso em produção.

Um aspecto metodológico relevante é o que pode ser descrito como um paradoxo de avaliação. Para calibrar e melhorar a qualidade dos dados sintéticos seria necessário compará-los com dados reais rotulados, o que torna o sintético um complemento dependente do real e não uma alternativa autônoma. Construir prompts capazes de gerar frases representativas sem nenhuma referência a dados reais é uma tarefa difícil na prática, e durante este trabalho foi observado que LLMs sem instruções específicas tendem a produzir conteúdo combinatório repetitivo, com baixa diversidade linguística. Esse comportamento sugere que a viabilidade da abordagem está condicionada à existência prévia de algum conjunto real para guiar o processo de geração.

A análise de custo também aponta na mesma direção. Vale registrar que este trabalho em si foi conduzido sem custo monetário, com a geração das 1.800 frases por nicho feita manualmente nas interfaces web em planos gratuitos ou pro limitado dos três LLMs, em aproximadamente três a quatro horas de trabalho por nicho. Mas essa abordagem manual não escala — em cenários de produção, o uso de API se torna obrigatório, e nesse cenário o cálculo muda. Usando estimativas de preços públicos de maio de 2026, gerar as 1.800 frases via API custaria menos de um dólar em qualquer um dos três modelos (saída em torno de 54 mil tokens). Classificar diretamente as mesmas 1.800 reviews via API em modo zero-shot custaria igualmente menos de um dólar, com a vantagem de entregar acurácia superior à dos classificadores treinados em dados sintéticos. A combinação de custo de geração via API, tempo de desenvolvimento, infraestrutura de treinamento e desempenho final inferior torna o caminho sintético desfavorável para a maior parte das aplicações comuns. A abordagem mantém algum valor em situações específicas, como cenários com restrições de privacidade que impeçam o envio de dados a APIs externas, necessidade de inferência offline ou em dispositivos embarcados, volumes muito altos de classificação onde o custo da API se torna proibitivo, exigências de compliance que demandem modelo proprietário, ou domínios com tão pouco dado disponível que a geração sintética se torne a única opção viável.

A diferença entre os dois nichos analisados acrescenta uma nuance importante. Apps mostrou resultados melhores que filmes e séries principalmente no *cross-domain* desbalanceado, com destaque para a V5 com BERTimbau (+13 pontos). Reviews de aplicativos têm vocabulário mais regular e objetivo (problemas técnicos concretos), enquanto reviews de filmes e séries têm linguagem narrativa mais elaborada. Isso sugere que a viabilidade de treinar com dados sintéticos depende do nicho: pode funcionar melhor em domínios de avaliação de produto e funciona pior em domínios com linguagem subjetiva extensa.

A principal contribuição deste trabalho está em demonstrar empiricamente esse conjunto de limitações e quantificá-las de forma sistemática, em dois nichos distintos e com cinco classificadores cobrindo desde modelos lineares baseados em TF-IDF até arquiteturas neurais com pretreino em larga escala. A evidência reunida permite afirmar que dados sintéticos gerados por LLMs ainda não são uma substituição prática para corpora reais em análise de sentimento em português brasileiro, mas oferecem um ponto de partida funcional para pesquisa exploratória, prototipagem inicial e cenários onde o uso de

dados reais é inviável por restrições externas. Como trabalhos futuros, seria interessante investigar se técnicas de adaptação de domínio (como combinar pequena quantidade de dados reais com bastante dado sintético) conseguem fechar o gap, e estender a análise para outros nichos com graus variados de subjetividade.

Referências

- Araujo, G. d., de Melo, T., and Figueiredo, C. M. S. (2024). Is ChatGPT an effective solver of sentiment analysis tasks in Portuguese? A preliminary study. In *Proceedings of the 16th International Conference on Computational Processing of Portuguese (PRO-POR 2024)*, pages 13–21, Santiago de Compostela, Espanha. Association for Computational Linguistics.
- de Souza, V. A., de Souza, É. F., and Meinerz, G. V. (2021). Análise de sentimento em tempo real. *Brazilian Journal of Development*, 7(1):11084–11091.
- Hellwig, N. C., Fehle, J., and Wolff, C. (2025). Exploring large language models for the generation of synthetic training samples for aspect-based sentiment analysis in low resource settings. *Expert Systems with Applications*, 261:125514.
- Jurafsky, D. and Martin, J. H. (2025). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*. Stanford University, 3rd edition. Online manuscript released August 24, 2025.
- Kansanon, D. J. and Moro, S. (2019). Análise de sentimentos em tweets em português brasileiro. In *Anais do BrasNAM 2019*. UFMG.
- Li, Z., Zhu, H., Lu, Z., and Yin, M. (2023). Synthetic data generation with large language models for text classification: Potential and limitations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*.
- Liu, R., Wei, J., Liu, F., Si, C., Zhang, Y., Rao, J., Zheng, S., Peng, D., Yang, D., Zhou, D., and Dai, A. M. (2024). Best practices and lessons learned on synthetic data for language models. In *Proceedings of COLM 2024*.
- Nadas, M., Diosan, L., and Tomescu, A. (2025). Synthetic data generation using large language models: Advances in text and code. *arXiv preprint arXiv:2503.14023*.
- Pang, B., Lee, L., and Vaithyanathan, S. (2002). Thumbs up? sentiment classification using machine learning techniques. In *Proceedings of EMNLP 2002*, pages 79–86.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., VanderPlas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Rossi, R. H. P. S. (2019). *Análise de sentimentos para o auxílio na gestão das Cidades Inteligentes*. Tese de doutorado, Universidade de São Paulo.
- Souza, F. and Filho, J. A. (2021). Sentiment analysis on Brazilian Portuguese user reviews. *arXiv preprint arXiv:2112.05459*. Publicado em IEEE LA-CCI 2022.

Zhang, W., Deng, Y., Liu, B., Pan, S., and Bing, L. (2024). Sentiment analysis in the era of large language models: A reality check. In *Findings of the Association for Computational Linguistics: NAACL 2024*, pages 3881–3906, Cidade do México, México.