Avaliando a Capacidade de Modelos de Aprendizado de Máquina Treinados com Dados Sintéticos de Críticas em Filmes e Séries

Luciana P. Nedel[1], Rafael H. Bordini[2], Flávio Rech Wagner[1], Jomi F. Hübner[3]

[1]Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)
Caixa Postal 15.064 – 91.501-970 – Porto Alegre – RS – Brazil

[2]Department of Computer Science – University of Durham
Durham, U.K.

[3]Departamento de Sistemas e Computação
Universidade Regional de Blumenal (FURB) – Blumenau, SC – Brazil

{nedel,flavio}@inf.ufrgs.br, R.Bordini@durham.ac.uk, jomi@inf.furb.br

Abstract. *This meta-paper describes the style to be used in articles and short papers for SBC conferences. For papers in English, you should add just an abstract while for the papers in Portuguese, we also ask for an abstract in Portuguese ("resumo"). In both cases, abstracts should not have more than 10 lines and must be in the first page of the paper.*

Resumo. *Este meta-artigo descreve o estilo a ser usado na confecção de artigos e resumos de artigos para publicação nos anais das conferências organizadas pela SBC. É solicitada a escrita de resumo e abstract apenas para os artigos escritos em português. Artigos em inglês deverão apresentar apenas abstract. Nos dois casos, o autor deve tomar cuidado para que o resumo (e o abstract) não ultrapassem 10 linhas cada, sendo que ambos devem estar na primeira página do artigo.*

1. General Information

All full papers and posters (short papers) submitted to some SBC conference, including any supporting documents, should be written in English or in Portuguese. The format paper should be A4 with single column, 3.5 cm for upper margin, 2.5 cm for bottom margin and 3.0 cm for lateral margins, without headers or footers. The main font must be Times, 12 point nominal size, with 6 points of space before each paragraph. Page numbers must be suppressed.

Full papers must respect the page limits defined by the conference. Conferences that publish just abstracts ask for **one**-page texts.

2. Fundamentação Teórica

Esta seção apresenta os conceitos que embasam o trabalho: análise de sentimento como tarefa de PLN, as técnicas de representação de texto utilizadas, os algoritmos de classificação adotados e o papel dos grandes modelos de linguagem na geração de dados sintéticos.

2.1. Análise de Sentimento

A análise de sentimento é uma das tarefas mais estudadas em Processamento de Linguagem Natural (PLN). O objetivo principal é identificar automaticamente a polaridade de um texto — se ele expressa uma opinião positiva, negativa ou neutra em relação a algum objeto, produto ou experiência [Jurafsky and Martin 2025]. As aplicações são diversas: desde monitoramento de redes sociais e análise de reputação de marcas até pesquisas de satisfação e moderação de conteúdo.

Do ponto de vista da granularidade, a análise de sentimento pode ser realizada em três níveis: no nível do documento, avaliando o sentimento geral do texto como um todo; no nível da sentença, classificando cada frase individualmente; e no nível de aspecto, identificando a polaridade em relação a atributos específicos de um produto ou serviço [Pang et al. 2002]. Neste trabalho, a classificação é feita no nível da sentença, com três classes possíveis: Positiva, Negativa e Neutra.

Um dos desafios conhecidos da tarefa é o tratamento de negações e ambiguidades linguísticas. Uma frase como "não gostei nada desse filme" tem polaridade oposta ao que seria esperado pela presença isolada do verbo "gostar", e esse tipo de construção tende a causar erros em classificadores baseados apenas em frequência de termos [Jurafsky and Martin 2025].

2.2. Representação de Texto: *Bag-of-Words* e TF-IDF

Para que algoritmos de aprendizado de máquina possam processar texto, é necessário converter as frases em representações numéricas. A abordagem *bag-of-words* (BoW) é uma das mais simples e tradicionais: cada documento é representado como um vetor de contagens de palavras, ignorando a ordem em que aparecem [Jurafsky and Martin 2025]. Apesar de sua simplicidade, essa representação ainda apresenta resultados competitivos em muitas tarefas de classificação de texto.

Uma extensão comum do BoW é o *Term Frequency–Inverse Document Frequency* (TF-IDF), que ajusta as contagens de palavras pela frequência inversa delas no corpus. A ideia é penalizar termos muito frequentes — como preposições e artigos — que aparecem em quase todos os documentos e, portanto, têm pouco poder discriminativo. Formalmente, o peso TF-IDF de um termo t em um documento d é dado por:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log\left(\frac{N}{\text{DF}(t)}\right) \tag{1}$$

onde N é o número total de documentos e $\text{DF}(t)$ é o número de documentos que contêm o termo t. O TF-IDF foi escolhido neste trabalho como método de vetorização por ser amplamente utilizado em tarefas de classificação de sentimento e por apresentar bom desempenho com classificadores clássicos [Rossi 2019].

2.3. Algoritmos de Classificação

2.3.1. Naive Bayes

O classificador Naive Bayes é um método probabilístico baseado no Teorema de Bayes, que assume independência condicional entre os atributos dado a classe. Embora essa

suposição raramente seja verdadeira na prática — daí o nome “naive” (ingênuo) —, o algoritmo apresenta resultados surpreendentemente bons em tarefas de classificação de texto [Jurafsky and Martin 2025]. Na versão multinomial, utilizada neste trabalho, o modelo calcula a probabilidade de cada classe dado o conjunto de termos presentes na frase e escolhe a classe de maior probabilidade a posteriori.

2.3.2. Regressão Logística

A Regressão Logística é um classificador discriminativo que aprende diretamente a fronteira de decisão entre as classes, ao contrário do Naive Bayes, que modela a distribuição gerativa dos dados [Jurafsky and Martin 2025]. Em geral, classificadores discriminativos tendem a superar o Naive Bayes quando há grande quantidade de dados, pois não impõem a suposição de independência entre as *features* [Pang et al. 2002]. Contudo, como discutido na seção de Resultados, os dados obtidos neste trabalho apresentaram o comportamento inverso, o que pode estar relacionado às características específicas dos dados sintéticos gerados por LLMs.

2.3.3. Support Vector Machine

A Support Vector Machine (SVM) é um algoritmo que busca o hiperplano de separação de máxima margem entre as classes no espaço de *features*. Com kernel linear, é especialmente eficaz para problemas de alta dimensionalidade como classificação de texto, onde o número de *features* (vocabulário) pode ser muito maior do que o número de exemplos [Jurafsky and Martin 2025]. Neste trabalho, o SVM com kernel linear foi utilizado como terceiro modelo de comparação.

2.4. Grandes Modelos de Linguagem e Geração de Dados Sintéticos

Grandes Modelos de Linguagem (*Large Language Models* — LLMs) são modelos baseados na arquitetura Transformer, pré-treinados em grandes corpora de texto para aprender representações ricas da linguagem. Nos últimos anos, modelos como GPT, Gemini e Claude demonstraram capacidade de gerar textos coerentes, fluentes e contextualmente adequados em diversas línguas e domínios [Jurafsky and Martin 2025].

Uma das aplicações emergentes dos LLMs é a geração de dados sintéticos para treinamento de modelos de aprendizado de máquina. Essa abordagem é especialmente interessante em cenários onde a obtenção de dados reais rotulados é cara ou difícil — como é frequentemente o caso em tarefas de PLN em português. A ideia central é usar os LLMs como geradores de exemplos de treinamento, reduzindo a dependência de anotação humana.

3. Trabalhos Relacionados

Esta seção revisa trabalhos que abordam análise de sentimento com aprendizado de máquina, com foco em aplicações em língua portuguesa e no uso de dados sintéticos para treinamento de classificadores.

3.1. Análise de Sentimento com Aprendizado de Máquina

O trabalho pioneiro de [Pang et al. 2002] estabeleceu que abordagens baseadas em aprendizado de máquina — especialmente Naive Bayes, SVM e Máxima Entropia — superam métodos baseados em regras para classificação de sentimento em resenhas de filmes. Os autores utilizaram o corpus de críticas do IMDb e observaram que o SVM com representação unigrama atingiu os melhores resultados, enquanto o Naive Bayes apresentou desempenho competitivo com menor custo computacional.

No contexto brasileiro, [Kansaon and Moro 2019] realizaram análise de sentimento em tweets em português, utilizando múltiplas variantes do Naive Bayes. Os autores reportaram acurácias entre 79% e 85% dependendo da configuração do classificador e do par de classes analisado, evidenciando que mesmo em língua portuguesa, com suas particularidades morfológicas, abordagens clássicas apresentam resultados satisfatórios.

[de Souza et al. 2021] propuseram um sistema de análise de sentimento em tempo real para notícias do mercado financeiro em português, utilizando TF-IDF combinado com Naive Bayes. O sistema atingiu acurácia de 76,8% na classificação de tweets de veículos jornalísticos. Os autores destacam o papel do pré-processamento — especialmente a remoção de *stopwords* e normalização textual — no desempenho final do classificador.

[Rossi 2019] desenvolveu um método de análise de sentimento aplicado a cidades inteligentes, utilizando classificadores como Regressão Logística, Naive Bayes Multinomial, SVM linear e Random Forest sobre representações BoW e TF-IDF. Os resultados demonstram que a escolha da técnica de extração de características impacta significativamente o desempenho, com TF-IDF apresentando ganhos consistentes sobre o BoW simples na maioria dos experimentos.

3.2. Dados Sintéticos para Treinamento de Modelos de PLN

A utilização de dados sintéticos gerados por LLMs para treinamento de modelos de aprendizado de máquina é uma área emergente de pesquisa. A motivação principal é reduzir o custo e o tempo associados à anotação manual de dados, que continua sendo um dos principais gargalos para o desenvolvimento de modelos de PLN em idiomas com menor disponibilidade de recursos, como o português.

Diferentemente dos trabalhos anteriores, que coletam dados reais de plataformas como Twitter e portais de avaliação, este trabalho investiga se é possível obter classificadores com desempenho competitivo utilizando exclusivamente dados gerados por LLMs. Além disso, a comparação entre três geradores distintos — ChatGPT 2.5, Gemini 2.5 e Claude Sonnet 4.5 — permite avaliar se há diferenças significativas na qualidade dos dados produzidos por cada modelo, contribuindo para o entendimento sobre a adequação de LLMs como substitutos de anotadores humanos em tarefas de análise de sentimento.

4. Metodologia

Neste tópico está a descrição e procedimentos escolhidos para a formação da base de dados sintética e o esclarecimento de como está imputada a definição de cada classe

(Positiva, Negativa, Neutra) utilizadas, para criação de prompts e dos dados sintéticos gerados nas ferramentas de IA.

4.1. Definição das Classes de Sentimento

Para garantir a consistência na geração e uma classificação mais coerente dos dados, foram estabelecidas definições para cada classe de sentimento (Positiva, Negativa, Neutra), focadas no nicho de filmes e séries, baseadas em conceitos fundamentais do processamento de linguagem natural [Jurafsky and Martin 2025].

Classe: Positiva Contempla as críticas ou comentários que expressam de forma clara e sem equívocos sentimentos de satisfação, alegria, admiração ou recomendação explícita sobre um filme ou série. Incluindo elogios a elementos específicos como atuação, roteiro, direção, fotografia, trilha sonora ou ao impacto emocional geral da obra.

> *Exemplo: "Adorei o filme, o roteiro é top e as atuações são ótimas. Recomendo a todos!"*

Classe: Negativa Contempla as críticas ou comentários que expressam de forma clara e sem equívocos sentimentos de insatisfação, desapontamento ou desaprovação sobre um filme ou série. Incluindo críticas a elementos específicos como atuação fraca, furos no roteiro, direção confusa, ritmo lento ou personagens mal desenvolvidos.

> *Exemplo: "Que decepção, o filme tem um roteiro cheio de furos e os personagens são muito chatos. Perdi meu tempo."*

Classe: Neutra Contempla os textos que apresentam informações factuais sobre um filme ou série, sem emitir um juízo de valor ou opinião. Incluindo sinopses, listagem de elenco, informações sobre o diretor, ano de lançamento, gênero, descrição de uma cena específica sem opinião ou perguntas sobre a obra.

> *Exemplo: "A série foi dirigida por Anna Kappel e estreou em 2025 na plataforma de streaming."*

5. First Page

The first page must display the paper title, the name and address of the authors, the abstract in English and "resumo" in Portuguese ("resumos" are required only for papers written in Portuguese). The title must be centered over the whole page, in 16 point boldface font and with 12 points of space before itself. Author names must be centered in 12 point font, bold, all of them disposed in the same line, separated by commas and with 12 points of space after the title. Addresses must be centered in 12 point font, also with 12 points of space after the authors' names. E-mail addresses should be written using font Courier New, 10 point nominal size, with 6 points of space before and 6 points of space after.

The abstract and "resumo" (if is the case) must be in 12 point Times font, indented 0.8cm on both sides. The word **Abstract** and **Resumo**, should be written in boldface and must precede the text.

6. CD-ROMs and Printed Proceedings

In some conferences, the papers are published on CD-ROM while only the abstract is published in the printed Proceedings. In this case, authors are invited to prepare two final versions of the paper. One, complete, to be published on the CD and the other, containing only the first page, with abstract and "resumo" (for papers in Portuguese).

7. Sections and Paragraphs

Section titles must be in boldface, 13pt, flush left. There should be an extra 12 pt of space before each title. Section numbering is optional. The first paragraph of each section should not be indented, while the first lines of subsequent paragraphs should be indented by 1.27 cm.

7.1. Subsections

The subsection titles must be in boldface, 12pt, flush left.

8. Figures and Captions

Figure and table captions should be centered if less than one line (Figure 1), otherwise justified and indented by 0.8cm on both margins, as shown in Figure 2. The caption font must be Helvetica, 10 point, boldface, with 6 points of space before and after each caption.

"No, you weren't downloaded.
Your were born."

Figure 1. A typical figure

In tables, try to avoid the use of colored or shaded backgrounds, and avoid thick, doubled, or unnecessary framing lines. When reporting empirical data, do not use more decimal digits than warranted by their precision and reproducibility. Table caption must be placed before the table (see Table 1) and the font used must also be Helvetica, 10 point, boldface, with 6 points of space before and after each caption.

9. Images

All images and illustrations should be in black-and-white, or gray tones, excepting for the papers that will be electronically available (on CD-ROMs, internet, etc.). The image resolution on paper should be about 600 dpi for black-and-white images, and 150-300 dpi for grayscale images. Do not include images with excessive resolution, as they may take hours to print, without any visible difference in the result.

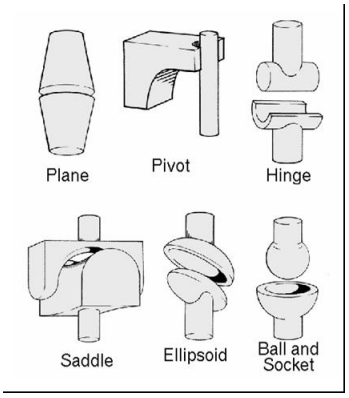

Figure 2. This figure is an example of a figure caption taking more than one line and justified considering margins mentioned in Section 8.

Table 1. Variables to be considered on the evaluation of interaction techniques

	Chessboard top view	Chessboard perspective view
Selection with side movements	6.02 ± 5.22	7.01±6.84
Selection with in-depth movements	6.29±4.99	12.22±11.33
Manipulation with side movements	4.66± 4.94	3.47±2.20
Manipulation with in-depth movements	5.71 ±4.55	5.37 ±3.28

References

de Souza, V. A., de Souza, É. F., and Meinerz, G. V. (2021). Análise de sentimento em tempo real. *Brazilian Journal of Development*, 7(1):11084–11091.

Jurafsky, D. and Martin, J. H. (2025). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*. Stanford University, 3rd edition. Online manuscript released August 24, 2025.

Kansaon, D. J. and Moro, S. (2019). Análise de sentimentos em tweets em português brasileiro. In *Anais do BrasNAM 2019*. UFMG.

Pang, B., Lee, L., and Vaithyanathan, S. (2002). Thumbs up? sentiment classification using machine learning techniques. pages 79–86.

Rossi, R. H. P. S. (2019). *Análise de sentimentos para o auxílio na gestão das Cidades Inteligentes*. Tese de doutorado, Universidade de São Paulo.